

Licença Creative Commons Attribution 4.0 International

# UniLex: Método Léxico para Análise de Sentimentos Textuais sobre Conteúdo de *Tweets* em Português Brasileiro\*

UniLex: Lexicon-Based Method for Textual Sentiment Analysis in Portuguese Brazilian Tweets Content

Karine França de Souza<sup>1</sup> Moisés Henrique Ramos Pereira<sup>2</sup> Daniel Hasan Dalip<sup>3</sup>

#### Resumo

Este artigo aborda a criação de um método computacional baseado em dicionário léxico, que seja capaz de analisar textos em idioma português brasileiro e de polarizar as palavras de acordo com os sentimentos por elas transmitidos. O estudo realizado visa detectar os sentimentos expressos nos textos da *Web* e comparar a abordagem proposta com métodos existentes, utilizando a aplicação *iFeel*, que retorna os resultados dos principais métodos para a análise de sentimentos textuais. Pode-se concluir que, por meio de experimentos em uma base de dados do *Twitter* em português brasileiro, o método proposto retorna os sentimentos associados nos textos analisados com uma acurácia melhor do que os métodos descritos em trabalhos relacionados.

Palavras-chave: Análise de Sentimentos. Dicionário Léxico. Método Léxico.

<sup>\*</sup>Submetido em 15/02/2017 - Aceito em 02/05/2017

<sup>&</sup>lt;sup>1</sup>Analista de Sistema na Companhia de Tecnologia da Informação do Estado de Minas Gerais (PRODEMGE) . Bacharel em Ciência da Computação, pelo UNI-BH, Brasil – karine.souza@prodemge.gov.br

<sup>&</sup>lt;sup>2</sup>Docente do Instituto Federal de Educação, Ciência e Tecnologia de Minas Gerais (IFMG). Mestre em Modelagem Matemática e Computacional, pelo CEFET-MG, Brasil – moises.pereira@ifmg.edu.br

<sup>&</sup>lt;sup>3</sup>Docente do Centro Federal de Educação Tecnológica de Minas Gerais (CEFET-MG). Doutor em Ciência da Computação, pela UFMG, Brasil – hasan@decom.cefetmg.br

#### **Abstract**

The main goal of this paper is to create a lexicon-based method, which infers the polarity of Brazilian Portuguese texts. To accomplish this, we perform a study aimed at detecting the sentiments in Web text. We also compare our approach with existing methods, using IFeel, a tool containing the implementation of many state-of-the-art methods of text sentiment analysis. Through experiments, in a dataset with Portuguese Twitter messages, we have shown that our approach can reach a better accuracy when compared with the state-of-the-art.

Keywords: Sentiment analysis. Dictionary Lexicon. Lexicon-based Method

# 1 INTRODUÇÃO

A intercomunicação é um meio fundamental para que as pessoas possam ter o conhecimento recíproco e criar vínculos para o seu crescimento pessoal e, até mesmo, profissional. Desde os anos 60, no período da guerra fria nos Estados Unidos, a *Internet* vem sendo utilizada como um importante meio de comunicação, que conquistou o seu espaço de forma rápida e eficaz.

É evidente que a *Internet* revolucionou o mundo e as pessoas como um todo. Segundo a pesquisa feita pelo Centro Regional para o Desenvolvimento da Sociedade da Informação (CETIC, 2014), em 2014, 94,2 milhões dos brasileiros possuíam acesso à *Internet* por meio de microcomputadores ou de dispositivos móveis. Dentre esses usuários, 76% a utilizavam para participar de redes sociais, o que indica que a comunicação virtual está cada vez mais comum e presente na vida dos brasileiros.

Atualmente, existem vários meios de se comunicar via *Web*. Dentre esses meios, existem algumas vias de comunicação que são públicas, onde pessoas podem expressar opiniões sobre produtos e serviços, tais como: blogs, revisões de produtos e redes sociais. Tais informações são valiosas para que empresas entendam melhor os seus consumidores.

Como a quantidade de informação é imensa e a análise manual da opinião dos textos é inviável, existem, atualmente, diversos métodos que intermediam a interpretação desses textos da *Web*. Esses métodos possibilitam descobrir a polaridade de um determinado texto, ou seja, se um texto expressa uma opinião positiva, negativa ou neutra.

Geralmente, os métodos descritos em trabalhos relacionados necessitam, como entrada, de textos na língua inglesa. Ou seja, quando o texto é de outra língua, ele não é classificado diretamente em sua língua nativa. O mesmo é traduzido para a língua inglesa e, logo após, classificado quanto ao seu sentimento (REIS et al., 2015).

Porém, a tradução pode adicionar ruídos devido à tradução incorreta das palavras e, com isso, aumentar o risco de erro na predição do sentimento do texto. Assim, é importante que existam métodos que polarizem as palavras ainda na linguagem nativa, para que o sentimento possa ser classificado com uma maior precisão.

Assim, este trabalho propõe um método com o objetivo de interpretar os sentimentos dos textos virtuais publicados em redes sociais em português. Para isso, será criado um dicionário léxico em que cada palavra será classificada como positiva, negativa ou neutra. Com esse dicionário, essa abordagem irá classificar o sentimento nas postagens. Experimentos foram realizados a partir de uma base com 14.083 *tweets* em português e os resultados indicam uma maior precisão do método proposto quando comparado aos demais utilizados.

Este artigo está dividido em 6 seções, incluindo esta Seção 1 de introdução. A Seção 2 apresenta a fundamentação teórica, abordando alguns dos principais conceitos utilizados para desenvolver o método proposto. A Seção 3 apresenta os trabalhos relacionados, fazendo-se uma análise crítica de seus resultados e suas contribuições. A Seção 4 apresenta a metodologia estruturada e descreve todo o processo de modelagem e implementação da abordagem proposta para

alcançar os objetivos traçados. A Seção 5 expõe os resultados alcançados com a metodologia proposta, incluindo a comparação com os métodos existentes e a devida representação gráfica dos testes realizados. Por fim, a Seção 6 descreve o fechamento dos resultados alcançados, observações e futuras implementações do trabalho.

# 2 FUNDAMENTAÇÃO TEÓRICA

Para a melhor compreensão das diretrizes propostas neste trabalho, faz-se necessário enunciar brevemente alguns pressupostos básicos quanto ao processamento linguístico para análise de sentimentos em conteúdo textual. Além disso, são apresentadas soluções consolidadas na literatura para alcançar o resultado final da aplicação.

Nesta seção, é exemplificada a implementação de métodos linguístico-computacionais da área de Inteligência Artificial que conseguem representar, por meio das palavras, o pensamento humano, bem como utilizar técnicas de recuperação da informação para a sua devida classificação.

A análise de sentimentos se baseia na teoria de que as palavras expressam os sentimentos das pessoas que as falam ou escrevem. De acordo com Narayanan et al. (2009), a análise de sentimentos tem por objetivo identificar e extrair de forma automática, as opiniões, sentimentos e emoções, expressados em um texto. Esse tipo de análise foi desenvolvida para que fosse possível captar informações sobre determinados assuntos e extrair um pensamento positivo, negativo ou neutro, conforme a polarização das palavras contidas nos textos analisados.

A polarização das palavras, segundo Gonçalves (2015), é a representação do grau de positividade, negatividade ou neutralidade emocional de uma frase. Sendo assim, a definição dessa polarização é fundamental para a realização da análise de sentimentos, pois ela irá definir o retorno que o dicionário léxico dará em cada análise.

Para realizar a análise de sentimentos, é necessário, inicialmente, efetuar o pré- processamento dos textos utilizados. Segundo Rezende (2003), o pré-processamento do texto para a realização da análise de sentimentos se faz necessário para as aplicações de métodos léxicos. Tal pré-processamento visa reduzir o volume dos dados, antes de iniciar a execução das etapas de análise. Isso é realizado por razão de limitações de memória ou tempo de processamento para bases de dados muito grandes.

Após o pré-processamento, o método de análise de sentimentos precisa representar cada texto e suas palavras. Nessas representações, cada palavra é representada por meio de um peso. Esse peso pode ser simplesmente sua frequência, ou, por exemplo, o valor TF-IDF.

Segundo Ricardo et al. (1999), TF indica a frequência de termos ou palavras que ocorrem em um determinado documento. Esse cálculo é complementado pelo inverso da frequência do termo na coleção de documentos, para diminuir o peso dos termos que ocorrem com muita frequência nesses documentos.

O TF-IDF é uma abreviação do inglês "Term Frequency-inverse Document Frequency",

que significa "Frequência do termo-inverso da Frequência nos Documentos". Segundo Ricardo et al. (1999), o termo de frequência (TF) indica que a ponderação de termos que ocorrem em um documento é proporcional à sua frequência. Essa atribuição é indicada como a primeira forma de ponderação de termos. Já o inverso da frequência nos documentos (IDF), se tornou uma interpretação estatística, que possui um conceito base para a ponderação de termos, que é especificado pela função inversa do número de documentos no qual esse termo ocorre.

Em vista da métrica utiliza para definição do peso das palavras analisadas, o valor TFIDF da palavra positiva ou negativa, aumenta proporcionalmente à medida que aumenta o número de ocorrências dela no documento. Esse valor é equilibrado pelo inverso da frequência, definida para cada termo. Com isto, é possível distinguir o fato de alguns termos serem geralmente mais comuns que outros no âmbito positivo ou negativo, conforme Equação 1 (RICARDO et al., 1999):

$$W_{t,d} = \left(\frac{Freq_{t,d}}{Max}\right) \times \log_2\left(\frac{N}{n_t}\right) \tag{1}$$

onde,  $W_{t,d}$  é o peso do termo t no documento d.  $Freq_{t,d}$  é a quantidade de vezes que o termo ocorre em um tweet. Max é o termo que possui maior ocorrência no tweet. N é o total de tweets na base de treino,  $n_t$  é o número de tweets na base de treino que possui o termo t.

#### 3 TRABALHOS RELACIONADOS

Existem outros trabalhos que possuem similaridade com a proposta deste artigo e que auxiliaram na decisão de qual metodologia utilizar. Como exemplo, pode-se citar o artigo de Gonçalves et al. (2016), que estuda a combinação de métodos *off-the-shelf*. Foi proposta a combinação desses métodos, obtendo-se outro com maior aplicabilidade, pois tal abordagem conseguia uma boa *performance* em diferentes contextos.

Outro exemplo encontrado é o artigo de Santos et al. (2014), que utiliza técnica de mineração de opiniões multilíngue para minerar as emoções em *corpus* paralelo e detectar diferenças estatísticas entre as classificações de acordo com os idiomas.

Outro artigo encontrado que estuda a análise de sentimentos em redes sociais (*Twitter*) foi o de Araújo et al. (2013), que visar realizar a análise em virtude de assuntos específicos comentados na rede social.

Os trabalhos relacionados utilizam, em sua maioria, a tradução de um dicionário léxico da língua inglesa. A abordagem proposta nesse artigo poderá auxiliar trabalhos semelhantes, com a classificação da palavra em sua forma nativa. Os próximos parágrafos apresentam os quatro métodos, já existentes, utilizados para análise de sentimentos.

O primeiro método estudado foi o *SentiWordNet*, que é uma ferramenta utilizada para a mineração de opiniões. Esse método é baseado no dicionário léxico *WordNet*, onde as palavras em inglês são agrupadas em conjuntos de sinônimos (*synsets*). Essa base, em sua versão 3.1 (2012), contém 155.287 palavras organizadas em 177.659 *synsets*, totalizando 206.941 pares de palavras/sentidos. O *SentiWordNet* associa a cada *synset* do *WordNet* três valores de pontuação

que indicam o sentimento de um texto, positivo, negativo e objetivo (neutralidade). Cada pontuação é obtida utilizando um método de aprendizagem de máquina semi-supervisionado e varia de 0 a 1. O resultado obtido pelo método é 0,000 para positividade, 0,850 para negatividade e 0,150 para objetividade. A avaliação do *SentiWordNet* foi feita utilizando-se um dicionário léxico rotulado (ESULI; SEBASTIANI, 2007).

O segundo método aplicado nas análises deste trabalho foi o *SentiStrength*, que utiliza aprendizado de máquina para realização da análise. Ele compara métodos de classificação supervisionados e não-supervisionados. O *SentiStrength* utiliza, para a classificação, uma versão expandida do dicionário LIWC. Para a validação do método, é utilizada uma base de dados rotulada por seis diferentes fontes, sendo elas: *Web 2.0*; *MySpace*; *Twitter*, posts no *Digg*; Comentários no fórum da BBC; Comentários no fórum do *Runners Word*; *Youtube* (THELWALL, 2013).

O terceiro método foi o *SenticNet* que realiza mineração de opinião e análise de sentimentos e explora técnicas de inteligência artificial e *Web* Semântica. O método utilizado na ferramenta engloba técnicas de Processamento de Linguagem Natural (PLN) para criar significados semânticos ou polaridade para aproximadamente 14.000 palavras (CAMBRIA et al., 2014).

O quarto método estudado foi o *Happiness Index*, que consiste em uma escala de sentimentos que utiliza o popular *Affective Norms for English Words* (ANEW), que é formado por uma coleção de 1.034 palavras associadas a dimensões afetivas de valência, excitação e dominância. O método calcula pontuações com valores entre 1 e 9, indicando a "quantidade" de felicidade apresentada em um dado texto. Posteriormente, ele calcula a frequência de cada palavra do ANEW, computa o peso médio encontrado, levando em consideração apenas o sentimento de valência (MITCHELL et al., 2013).

## 4 MATERIAIS E MÉTODOS

O método proposto utilizou um *dataset* contendo 14.083 *tweets* coletados da rede social *Twitter*, tendo como principal assunto a política, que foram rotulados e comparados para a criação da base do dicionário. O dicionário foi nomeado de UniLex referindo-se à unificação de diversas técnicas da literatura para a composição de um método de dicionário léxico.

Para a construção do trabalho, foram definidas etapas que englobavam desde a coleta dos dados nas redes sociais até a comparação com os métodos já existentes. O fluxo de execução, que representa a metodologia utilizada, pode ser visto na Figura 1, que esboça as etapas necessárias para a idealização do trabalho.

#### 4.1 Processamento do texto

O processamento do texto é fundamental para a execução do trabalho, pois, nesta etapa, é realizada a eliminação de acentuações, abreviações, preposições, artigos e conectivos das palavras conhecidas da língua portuguesa.

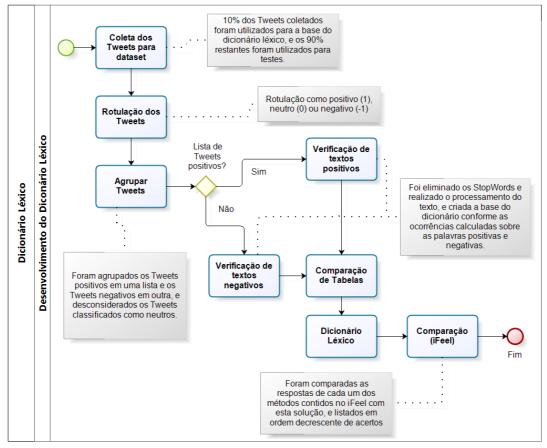


Figura 1 - Fluxo Geral da Abordagem Proposta

Fonte: Elaborada pelos autores

A eliminação dos acentos e abreviações é feita para igualar as palavras, pois, quando inseridas em redes sociais, elas podem sofrer alterações tanto por causa da cultura que os usuários possuem na escrita ao se expressar, como também por erros de digitação ou ortográficos. Assim, do mesmo modo, acontece com as abreviações. Elas serão transformadas para a forma correta da linguagem, e a análise não tratará as mesmas palavras com sentidos diferentes.

A eliminação das preposições, artigos e conectivos visa subtrair as palavras que não agregam um sentido específico na frase. Em outras palavras, servem apenas para ligar uma palavra a outra, e não devem ser consideradas na análise. Essas palavras são chamadas de *stopwords*. Tais palavras são removidas por não serem relevantes, ou seja, não traduzirem a essência das palavras quando não acompanhadas de outras que podem ser classificadas como positivas, negativas ou neutras. As *stopwords* formam uma lista conhecida como *stoplist* (vide Anexo 1), que, segundo a ferramenta *Snowball*, contém um conjunto de 250 conectivos, que foram removidos das frases analisadas.

## 4.2 Coleta, Rotulação e Tratamento dos tweets contidos no dataset

Para este artigo, foi realizada a coleta de 14.083 *tweets*, onde 10% desse total foi utilizado para a base de treinamento e 90% utilizado para a base de testes. Os *tweets* foram divididos em 15 arquivos CSV, sendo 14 planilhas de 1.000 *tweets* e 1 planilha de 83 *tweets*.

Para a rotulação dos *tweets* coletados, foi realizado, manualmente, a classificação dos textos, indicando se o sentimento contido na frase é positivo (1), negativo (-1) ou neutro (0). Na fase de classificação das polaridades, foram consideradas as intenções que o usuário teve ao digitar o *tweets*. A opinião do rotulador não foi levada em consideração, apenas foi analisado o que o *tweets* transmitiam. Os *tweets* com datas, marcação de outros usuários, *hashtags* foram considerados comentários neutros (0). A rotulação foi realizada por quatro rotuladores, sendo que cada um rotulou aproximadamente 3.500 *tweets* do *dataset*.

Para a criação da base de treinamento, foram selecionados 10% da coleção por um algoritmo de sorteio aleatório sem repetição. Logo após, foram agrupados todos os *tweets* classificados como positivos em um arquivo TXT, e os textos indicados como negativos em outro arquivo separado. Nessa etapa, foram desconsideradas as palavras classificadas efetivamente como neutras, pois o objetivo é identificar as palavras que influenciam na polarização de um dicionário léxico.

# 4.3 Verificação de Textos Positivos e Negativos

Nessa outra etapa, foi identificada a necessidade de se criar três tabelas de símbolos. A tabela de símbolos é uma estrutura de dados (árvore ou tabela de *hash*), utilizada por um compilador para armazenar informações de identificadores:

- A primeira tabela [TB\_SIN\_01], armazena todas as palavras identificadas como *stopwords* para métodos de recuperação de informação na língua portuguesa;
- A segunda tabela [TB\_SIN\_02] armazena as palavras cujas polaridades foram classificadas como positivas;
- A terceira [TB\_SIN\_03] armazena as palavras classificadas como negativas.

Foi verificado se a palavra existe na tabela de símbolos "StopWords". Se sim, ela é descartada. Caso contrário, verifica-se se ela está em uma das outras duas tabelas de símbolos "Positivas" e "Negativas". Caso esteja, é contabilizado mais uma ocorrência para a palavra, indicando quantas vezes ela foi classificada como positiva ou negativa. Caso contrário, ela é adicionada na tabela e é contada uma ocorrência, conforme ilustrado pela Figura 2.

Esta ação é realizada para definir o quão positiva ou negativa é a palavra. Este número de ocorrência contabilizada se justifica para definição do peso que cada palavra possui, para, logo após, este peso ser utilizado para estimar a polaridade de um *post*.

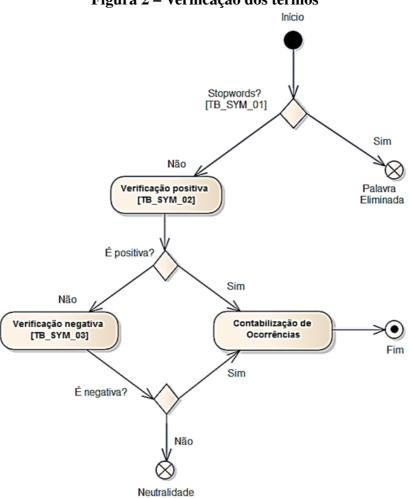


Figura 2 – Verificação dos termos

Fonte: Elaborada pelos autores

Uma segunda abordagem utilizada para a criação e definição do peso das palavras foi o valor TF-IDF. Esta abordagem também foi utilizada para a realização das comparações do UniLex com os outros métodos propostos (Seção 5).

## 4.4 Comparação de Tabelas

A comparação das tabelas de símbolos visa identificar quais as palavras possuem as ocorrências equivalentes ou muito próximas. Caso a porcentagem de ocorrências da palavra em uma das tabelas (positivas ou negativas) for maior que 60% do total de ocorrências, então ela se mantém em uma tabela e é eliminada da outra. Além disso, quando as ocorrências foram iguais em ambas as tabelas, a palavra é removida das duas tabelas.

Com isto, é possível realizar um filtro mais específico nas palavras contidas nas tabelas, para que a classificação seja mais eficiente e estabeleça um equilíbrio entre o positivo e o negativo, indicando qual das tabelas tem mais influência na palavra para que ela permaneça com aquele sentimento no retorno da análise.

A partir da comparação, será identificado, nas tabelas de símbolos, um novo campo

que concatena o resultado obtido na ocorrência das palavras, como o valor 1 para palavras positivas e -1 para palavras negativas. Após a concatenação, as tabelas positivas [TB\_SIN\_02] e negativas [TB\_SIN\_03] foram congregadas como uma base para a quarta tabela de símbolos, o próprio dicionário léxico [TB\_SIN\_04], totalizando 3.845 palavras entre positivas e negativas. A exemplificação sobre o fluxo descrito para a construção das tabelas de símbolos pode ser vista na Figura 3.

TB\_SYM\_01

TB\_SYM\_02

Positivas

TB\_SYM\_04

TB\_SYM\_03

Dicionário Léxico

Negativas

Figura 3 – Exemplificação do fluxo das Tabelas de Símbolos

Fonte: Elaborada pelos autores

O dicionário léxico é um conjunto de palavras armazenadas em um *dataset*, que polariza as palavras que o compõe e retorna o símbolo que melhor a representa. A utilização do dicionário léxico auxilia na classificação das palavras, pois nele cada palavra possui um símbolo que a indica como negativa (-1), neutra (0) e positiva (1).

## 4.5 Implementação

Após a modelagem dos métodos utilizados neste trabalho, são detalhadas a seguir as técnicas de implementação e as aplicações utilizadas para o desenvolvimento do dicionário léxico. A implementação realizada visa criar uma solução na linguagem nativa, para que seja possível encontrar a polarização das palavras de maneira mais eficiente que a dos métodos atuais.

Para o desenvolvimento, foi utilizado uma IDE para a codificação do método léxico e para a aplicação *Web* (Eclipse Kepler). Para a automatização do processo na tradução das palavras para o inglês, foi utilizado a API do Google, nomeada de "*Goslate*", um rastreador sofisticado, que detecta e traduz as palavras para um determinado idioma e um rastreador sofisticado, que detecta e traduz as palavras para um determinado idioma, e permite por meio do método [*concurrent.futures*], otimizar o processamento utilizando uma solução multi-thread para acelerar a tradução maciça. A tradução é necessária, pois os métodos do estado da arte existentes processam apenas o inglês.

Após a tradução das palavras do português para o inglês, para que os outros métodos pudessem retornar o sentimento associado aos *tweets*, foram realizados testes na aplicação (Seção

5). Para isso, foi utilizada a aplicação "*iFeel*", que retorna da sua análise os resultados encontrados em cada um dos métodos (ARAUJO et al., 2016), onde é possível classificar a proposta deste trabalho com os demais.

Em vista disto, é preciso gerar um arquivo com as palavras traduzidas para o processamento. Cada palavra será consultada na tabela de símbolos (dicionário), e se a palavra não for encontrada, retornará 0. Se a palavra for encontrada, será retornado o produto gerado através do termo, conforme a Equação 2:

$$(Peso) \times (Polaridade)$$
 (2)

onde, peso é a quantidade de vezes que o termo se repete nos *tweets* do *dataset* e polaridade é a classificação dada ao *tweet*, 1 (positivo), 0 (neutro), -1 (negativo).

Após encontrado o produto, foi realizado o somatório dos retornos de cada termo. Se o somatório do produto dos termos, for maior que 0, o retorno será positivo. Se igual a 0, o retorno será neutro. Se menor que 0, o retorno será negativo, conforme a Equação 3.

$$\sum E1 + E2...En > 0 \rightarrow (Positivo)$$

$$\sum E1 + E2...En = 0 \rightarrow (Neutro)$$

$$\sum E1 + E2...En < 0 \rightarrow (Negativo)$$
(3)

onde, E é o produto do termo.

## **5 RESULTADOS EXPERIMENTAIS**

Os testes no dicionário léxico foram feitos utilizando-se 90% dos *tweets* coletados que compõem a base de teste. Para a realização dos testes, os *tweets* foram submetidos para a aplicação *iFeel* e traduzidos para o idioma inglês. Após a conclusão da análise, os resultados de cada um dos 18 métodos utilizados pela aplicação foram armazenados em um vetor. Finalmente, tais resultados foram comparados com os resultados obtidos pelo UniLex.

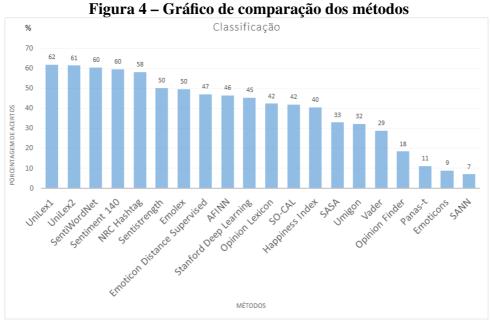
## 5.1 Comparação com os métodos relacionados utilizando o iFeel

O *iFeel* 2.0 é uma aplicação *Web* gratuita, que permite detectar sentimentos em qualquer forma de texto, incluindo dados de mídias sociais não estruturados. Por meio dele, é possível utilizar 18 métodos de análise de sentimentos, em sua versão atualizada em 30 de julho de 2016, sendo eles: *AFINN*, *Emolex*, *Emoticons*, *EmoticonDS*, *Happiness Index*, *OpinionFinder*, *NR-CHashtag*, *Opinion Lexicon*, *Panast*, *SANN*, *SASA*, *Sentiment140*, *Sentistrength*, *SentiWordNet*, *SOCAL*, *StanfordDeep Learning*, *Umigon*, *Vader* (MESSIAS et al., 2016).

O teste realizado englobou a análise da base do UniLex, tanto pela base gerada pelo

produto das palavras, como a que utilizou a abordagem TF-IDF. O resultado de ambas foi basicamente o mesmo.

O UniLex foi o melhor classificado, com a base dos produtos das palavras (UniLex1), obtendo 62% de acertos dos *tweets* analisados. A 2<sup>a</sup> colocação foi a da base da abordagem TFIDF (UniLex2), com 61% de acertos, mediante os métodos comparados pelo *iFeel*. A classificação dos métodos realizadas nessa análise, se deu pela diretriz dos métodos existentes na aplicação *iFeel*, versus a porcentagem de acertos de cada um, exemplificada na Figura 4.



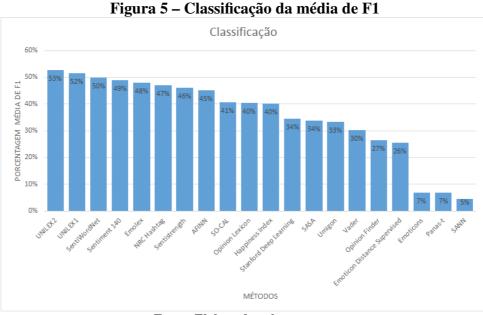
Fonte: Elaborada pelos autores

Todavia, os métodos *SentiWordNet*, *Sentiment140*, *NRC Hashtag* e *UniLex* em suas duas abordagens ficaram com a porcentagem de acertos muito próximas, entre 58 a 62%. Em vista disso, foi realizado o cálculo da precisão por classe de polarização, visando obter a maior exatidão no resultado da classificação dos métodos. Para isso, se fez necessário calcular a média hormônica. Essa métrica, denominada F1, realiza uma ponderação entre os valores da precisão e da revocação conforme a Equação 4 (NOGUEIRA, 2012).

$$F1(C) = \frac{(2 * Precisão(C) * Revocacão(C))}{(Precisão(C) + Revocacão(C))} \tag{4}$$

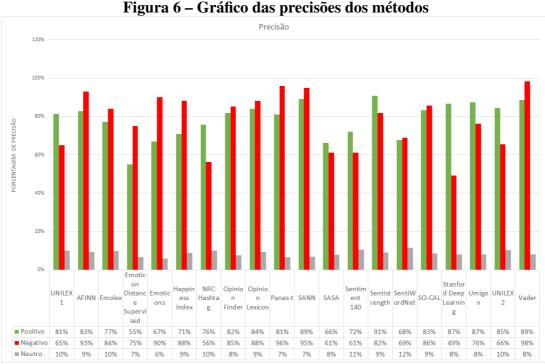
onde, F1(C) é o F1 da classe C. A classe pode ser indicada como positiva, negativa ou neutra. Precisão(C) é o total de *tweets* que o método acertou na classe C dividido pelo total de *tweets* que o método classificou na classe C (contabilizando acertos e erros). Revocação(C) é o total de *tweets* que o método acertou na classe C dividido pelo total de *tweets* rotulados como positivos na base de teste.

Após a análise do F1 dos métodos, foi possível verificar a combinação entre a precisão e a revocação, exemplificado no gráfico que indica a classificação, considerando a média de F1 na classe C (ver Figura 5), em que o UniLex foi o segundo melhor colocado na abordagem dos produtos dos termos (UniLex1) e a 1<sup>a</sup> classificação na abordagem TF-IDF (UniLex2), obtendo 2% de vantagem sobre o terceiro colocado, o método *SentiWordNet*.



Fonte: Elaborada pelos autores

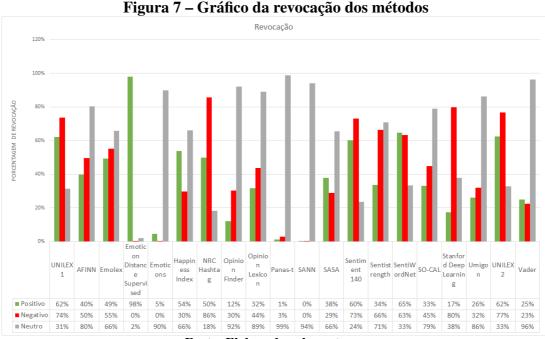
O gráfico da precisão por classe em cada método pode ser analisado na Figura 6, onde todos são classificados pelo total de *tweets* que cada método acertou na classe C (positivo, negativo, neutro), dividido pelo total de *tweets* que o método classificou na classe C (contabilizando acertos e erros de cada um).



Fonte: Elaborada pelos autores

O gráfico de revocação obtido por cada método pode ser analisado na Figura 7, onde todos são classificados pelo total de *tweets* que acertou na classe C (positivo, negativo, neutro), dividido pelo total de *tweets* rotulados como positivos, negativos e neutros na base de teste.

É possível verificar que, com a análise da média das medidas dos métodos, o resultado obtido para a classificação fez-se mais claro, mostrando o que cada um retornou nas polaridades



Fonte: Elaborada pelos autores

positivas, negativas e neutras.

O método Vader obteve uma precisão muito alta, porém a média de F1 muito baixa. Em vista dos resultados obtidos graficamente, é possível verificar que esse fato se justifica, pelo método classificar as frases que, realmente, possuem sentimentos positivos ou negativos. Em outras palavras, caso não seja obtido uma porcentagem aceitável para tal classificação na classe, o método retorna que aquela frase é neutra, indicando apenas, os sentimentos que o mesmo possui certeza de sua classificação.

## 6 CONCLUSÃO

O presente trabalho utiliza a linguagem nativa (português) para a geração da base de um dicionário léxico. Com isso, foi possível interpretar sentimentos textuais por meio da polarização das palavras extraída da classificação manual dos *tweets* coletados, indicando seus sentimentos como positivos, negativos ou neutros, (1, -1, 0, respectivamente) e transmitindo, assim, o sentido aos textos virtuais submetidos ao método.

A abordagem utilizando o TF-IDF não obteve resultado satisfatório, pois o termo calculado na frequência ( $Freq_{t,d}$ ), Equação 1, não ocorreu muitas vezes nos *tweets*. Os *tweets* coletados em grande maioria foram relacionados à política, como nomes de partidos e entidades políticas.

A análise de classificação obtida pela média dos métodos por meio da precisão e revocação indicou com maior exatidão os valores retornados por cada método nas polaridades. Isso fez com que a classificação geral dessa abordagem alcançasse resultados mais satisfatórios, e mostrasse a real condição do método nas perspectivas realizadas.

O trabalho obteve uma performance superior em comparação aos demais métodos tes-

tados. Isso indica que, ao analisar os sentimentos utilizando a linguagem nativa, no caso, o português brasileiro, ocorre um ganho considerável em seu retorno. Isso é possível por que o presente método é capaz de traduzir de maneira mais clara o sentimento contido nos textos, não obtendo ruídos ao ser traduzido por outras linguagens, como o inglês, que é muito utilizado para a realização da análise de sentimentos.

Visando melhorar ainda mais os resultados e a usabilidade da aplicação, foi pensado em pontos para o aprimoramento e precisão da análise. O primeiro seria analisar os *emoticons* inseridos nos textos, para que os sentimentos transmitidos por eles também sejam classificados, fazendo com que o resultado da análise fique mais concreto, e se aproxime ainda mais do sentimento contido na frase.

O segundo ponto seria realizar a rotulação com maior quantidade de rotuladores e *tweets*, para obter um resultado ainda mais próximo da realidade, fazendo com que a base do UniLex se torne mais robusta.

Aplicar as duas abordagens do UniLex, por meio do produto e do TF-IDF, para *datasets* mais genéricos ou de domínio mais específico é uma proposta. Com isso, espera-se verificar se existem casos em que uma abordagem seja realmente melhor do que a outra, ou se continuam gerando a mesma polaridade quase sempre.

# REFERÊNCIAS

ARAÚJO, Matheus et al. Métodos para análise de sentimentos no twitter. In: PRAZERES PAULO N.M. SAMPAIO, André Santachê Celso A.S. Santos Rudinei Goularte Cássio V.S (Ed.). **Proceedings of the 19th Brazilian symposium on Multimedia and the Web (Web-Media'13)**. [S.l.]: ACM, 2013. (WebMedia '13).

ARAUJO, Matheus et al. An evaluation of machine translation for multilingual sentence-level sentiment analysis. In: OSSOWSKI, Sascha (Ed.). **Proceedings of the 31st Annual ACM Symposium on Applied Computing**. [S.1.], 2016. p. 1140–1145.

CAMBRIA, Erik; OLSHER, Daniel; RAJAGOPAL, Dheeraj. Senticnet 3: a common and common-sense knowledge base for cognition-driven sentiment analysis. In: STRACUZZI, David Leake David (Ed.). **Proceedings of the twenty-eighth AAAI conference on artificial intelligence**. [S.l.], 2014. p. 1515–1521.

CETIC. **Apresentação dos principais resultados TIC Domicílios**. 2014. Http://goo.gl/m5X5Ms. Acesso em: 25 mar 2016.

ESULI, Andrea; SEBASTIANI, Fabrizio. Sentiwordnet: A high-coverage lexical resource for opinion mining. **Evaluation**, p. 1–26, 2007.

GONÇALVES, Pollyanna et al. On the combination of off-the-shelf sentiment analysis methods. In: ACM. **Proceedings of the 31st Annual ACM Symposium on Applied Computing**. [S.1.], 2016. p. 1158–1165.

GONÇALVES, Pollyanna de Oliveira. Um benchmark para comparação de métodos para análise de sentimentos. UFMG, 2015.

MESSIAS, Johnnatan et al. Towards sentiment analysis for mobile devices. In: IEEE. Advances in Social Networks Analysis and Mining (ASONAM), 2016 IEEE/ACM International Conference on. [S.l.], 2016. p. 1390–1391.

MITCHELL, Lewis et al. The geography of happiness: Connecting twitter sentiment and expression, demographics, and objective characteristics of place. **PloS one**, Public Library of Science, v. 8, n. 5, p. e64417, 2013.

NARAYANAN, Ramanathan; LIU, Bing; CHOUDHARY, Alok. Sentiment analysis of conditional sentences. In: ASSOCIATION FOR COMPUTATIONAL LINGUISTICS. **Proceedings of the 2009 Conference on Empirical Methods in Natural Language Processing: Volume 1-Volume 1.** [S.l.], 2009. p. 180–189.

NOGUEIRA, Iuri Deolindo. Desenvolvimento de um software de comunicação online entre diferentes idiomas com tratamento de expressões e linguagens encontradas em ambientes de chats. p. 59, 2012.

REIS, Julio CS et al. Uma abordagem multilingue para análise de sentimentos. In: IV Brazilian Workshop on Social Network Analysis and Mining (BraSNAM 2015). [S.l.: s.n.], 2015.

REZENDE, Solange Oliveira. **Sistemas Inteligentes - Fundamentos e Aplicações**. Barueri, SP, Brasil: Manole, 2003. ISBN 85-204-1683-7. Disponível em: <a href="http://www.manole.com.br/cgi/supercart.exe/idSearch?ok=detalhes.html%nothing=nada.html%b=221l%prodl\_id=197l%storel\_friend=ledepto=94">http://www.manole.com.br/cgi/supercart.exe/idSearch?ok=detalhes.html%nothing=nada.html%b=221l%prodl\_id=197l%storel\_friend=ledepto=94>.

RICARDO, Baeza-Yates et al. **Modern information retrieval**. [S.l.]: Pearson Education India, 1999.

SANTOS, Aline Graciela Lermen dos; BECKER, Karin; MOREIRA, Viviane. Mineração de emoções em textos multilíngues usando um corpus paralelo. 2014.

THELWALL, Mike. Heart and soul: Sentiment strength detection in the social web with sentistrength. **Proceedings of the CyberEmotions**, Citeseer, p. 1–14, 2013.

### A ANEXOS

## A.1 Anexo 1 - StopList

a agora ainda alguem alguma algumas alguns ampla amplas amplo amplos ante antes ao aos apos aquela aquelas aquele aqueles aquilo as ate atraves cada coisa coisas com como contra contudo da daquele daqueles das de dela delas dele deles depois dessa dessas desse desses desta destas deste deste deve devem devendo dever devera deverao deveria deveriam devia deviam disse disso disto dito diz dizem do dos e ela elas ele eles em enquanto entre era essa essas esse esses esta estamos estao estas estava estavam estavamos este estes estou eu fazendo fazer feita feitas feito feitos foi for foram fosse fossem grande grandes ha isso isto ja la lhe lhes lo mas me mesma mesmas mesmo mesmos meu meus minha minhas muita muitas muito muitos na nao nas nem nenhum nessa nessas nesta nestas ninguem no nos nossa nossas nosso nossos num numa nunca o os ou outra outras outro outros para pela pelas pelo pelos pequena pequenas pequenos per perante pode podendo poder poderia poderiam podia podiam pois por porem porque posso pouca poucas pouco poucos primeiros primeiros propria proprias proprios quais qual quando quanto quantos que quem sao se seja sejam sem sempre sendo sera serao seu seus si sido so sob sobre sua suas talvez tambem tampouco te tem tendo tenha ter teu teus ti tido tinha tinham toda todas todavia todo todos tu tua tuas tudo ultima ultimas ultimos um uma umas uns vendo ver vez vindo vir vos vos Lista conforme ferramenta Snowball, com 250 conectivos da língua portuguesa utilizados em frases, nomeados de stopwords (Subseção 4.1).